



Instituto Tecnológico y de Estudios Superiores de Monterrey

Campus Estado de México

Práctica No. 3

Carlos Manuel Ramos Gastélum A01253791

Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Momento de Retroalimentación: Módulo 2 Uso de un framework o librería de aprendizaje automático
para implementar una solución.

Prof. Jorge Adolfo Ramírez Uresti

Miércoles 09 de septiembre del 2026

1. Introducción

El objetivo de este proyecto es implementar y evaluar un algoritmo de Random Forest para clasificar tumores de mama como benignos o malignos. La implementación se realizó en Python utilizando Scikit-learn, con el propósito de demostrar el uso y configuración de un framework de aprendizaje máquina, así como la preparación de datos, entrenamiento, predicción y evaluación de un modelo de clasificación.

Random Forest es un método de aprendizaje supervisado basado en un conjunto de árboles de decisión. Cada árbol se entrena utilizando muestras obtenidas mediante bootstrap y subconjuntos de características, y las predicciones individuales se combinan para obtener la clasificación final. Esta estrategia permite reducir la varianza de un árbol individual y suele producir modelos robustos para problemas de clasificación.

2. Dataset

El conjunto utilizado corresponde al Breast Cancer Wisconsin (Diagnostic). Contiene 569 observaciones y 32 columnas. La variable **diagnosis** es la variable objetivo y contiene dos clases: B (benigno) y M (maligno). La columna **id** funciona únicamente como identificador de cada registro y fue excluida del entrenamiento para evitar utilizar información que no representa una característica del tumor.

Característica	Valor
Registros totales	569
Columnas totales	32
Características utilizadas	30
Variable objetivo	diagnosis
Clases	B = Benigno; M = Maligno
Entrenamiento	455 registros (80%)

Prueba	114 registros (20%)
--------	---------------------

La división entre entrenamiento y prueba se realizó mediante **train_test_split**, utilizando 80% de los datos para entrenar el modelo y 20% para evaluarlo. Se utilizó **stratify=y** para conservar la proporción de las clases en ambos subconjuntos y **random_state=42** para hacer reproducible el experimento.

3. Implementación y configuración del modelo

La implementación utiliza la clase **RandomForestClassifier** de Scikit-learn. La configuración empleada fue la siguiente:

Parámetro	Configuración	Propósito
n_estimators	100	Número de árboles del bosque


Parámetro	Configuración	Propósito
criterion	gini	Criterio para medir la calidad de las divisiones
max_depth	None	No se impone una profundidad máxima
min_samples_split	2	Mínimo de muestras para dividir un nodo
min_samples_leaf	1	Mínimo de muestras en una hoja
max_features	sqrt	Características consideradas en cada división
bootstrap	True	Uso de muestras bootstrap para cada árbol
random_state	42	Reproducibilidad
n_jobs	-1	Uso de los núcleos disponibles

Una vez entrenado el modelo, se utilizó el método **predict** sobre el conjunto de prueba para obtener las clasificaciones. La evaluación se realizó sin utilizar los datos de prueba durante el entrenamiento.

4. Resultados

El modelo obtuvo un desempeño elevado sobre el conjunto de prueba. Las métricas calculadas fueron:

Métrica	Resultado
Accuracy	97.37%
Precision	100.00%
Recall (Maligno)	92.86%
F1-Score	96.30%



5. Análisis de la matriz de confusión

La matriz de confusión obtenida fue $[[72, 0], [3, 39]]$. Esto representa 72 casos benignos correctamente clasificados, 39 casos malignos correctamente clasificados, ningún falso positivo y 3 falsos negativos.


El accuracy de 97.37% indica que el modelo clasificó correctamente 111 de los 114 casos del conjunto de prueba. La precision de 100% para la clase maligna significa que todos los casos que el modelo predijo como malignos fueron realmente malignos.

El recall de la clase maligna fue de 92.86%. Esta métrica resulta especialmente relevante para el problema, ya que mide la proporción de tumores malignos que el modelo logró identificar. En este experimento fueron detectados 39 de los 42 casos malignos, mientras que 3 fueron clasificados incorrectamente como benignos. Estos tres falsos negativos constituyen el principal aspecto que debe considerarse al interpretar el desempeño.

El F1-score de 96.30% muestra un buen equilibrio entre precision y recall para la clase maligna. En conjunto, las métricas indican que el modelo presentó un desempeño sólido en el conjunto de prueba.

6. Importancia de características

Random Forest permite estimar la importancia relativa de las características utilizadas por los árboles. Las siguientes son las diez características con mayor importancia en el modelo entrenado:



Característica	Importancia
area_worst	0.1514
concave points_worst	0.1265
radius_worst	0.0935

perimeter_worst	0.0836
concave points_mean	0.0811
perimeter_mean	0.0771
radius_mean	0.0620
concavity_mean	0.0508
area_mean	0.0459
concavity_worst	0.0300

7. Conclusión

La implementación de Random Forest mediante Scikit-learn permitió construir un clasificador capaz de distinguir entre tumores benignos y malignos con un desempeño elevado en el conjunto de prueba. El modelo alcanzó un accuracy de 97.37%, precision de 100%, recall de 92.86% y F1-score de 96.30%.

La matriz de confusión mostró que no se produjeron falsos positivos, aunque se presentaron tres falsos negativos. Debido a la naturaleza del problema, estos últimos son especialmente importantes, ya que representan casos malignos que el modelo clasificó como benignos. Por ello, aunque los resultados son

favorables, el modelo no debe interpretarse como una herramienta de diagnóstico médico y sería necesario realizar validaciones adicionales antes de considerar cualquier aplicación clínica.

Finalmente, el proyecto demuestra el uso de un framework de aprendizaje máquina para configurar, entrenar, evaluar y analizar un algoritmo de Random Forest. El experimento es reproducible debido a la configuración explícita de los parámetros y al uso de un valor fijo de random_state.